
Métodos Computacionales 2023
Trabajo Práctico 1:
Regresión Lineal Múltiple

Valentino Pivotto
Luciano Silva Davidov

2 Ejercicios

Primera parte. El objetivo de esta sección es deducir una fórmula para la solución óptima β^* siguiendo los pasos a continuación:

a) Mostrar que el espacio columna de la matriz X es un subespacio vectorial de \mathbb{R}^n :

$$Col(X) = \{b \text{ en } \mathbb{R}^n \text{ tales que } b = X\beta \text{ con } \beta \text{ variando en } \mathbb{R}^p\}$$

Subespacio - Definición

Un subespacio de \mathbb{R}^n es cualquier conjunto H en \mathbb{R}^n que cumpla con las siguientes 3 propiedades:

- El vector cero pertenece a H
- Para cada \mathbf{u} y \mathbf{v} en H , la suma $\mathbf{u}+\mathbf{v}$ está en H
- Para cada \mathbf{u} en H y cada escalar c , el vector $c\mathbf{u}$ está en H

Luego, aplicando esta definición con $H = Col(X)$:

$$Col(X) = Gen\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p\}$$

- El vector cero pertenece a $Col(X)$ ya que

$$\mathbf{0} = 0 * \mathbf{x}_1 + 0 * \mathbf{x}_2 + \dots + 0 * \mathbf{x}_p$$

- Para cada \mathbf{u} y \mathbf{v} en $Col(X)$, la suma $\mathbf{u}+\mathbf{v}$ está en $Col(X)$ puesto que existen i, j tal que:

$$\mathbf{u} = s_1 \cdot \mathbf{x}_1 + s_2 \cdot \mathbf{x}_2 + \dots + s_p \cdot \mathbf{x}_p$$

$$\mathbf{v} = t_1 \cdot \mathbf{x}_1 + t_2 \cdot \mathbf{x}_2 + \dots + t_p \cdot \mathbf{x}_p$$

$$\mathbf{u}+\mathbf{v} = (s_1 + t_1) \cdot \mathbf{x}_1 + (s_2 + t_2) \cdot \mathbf{x}_2 + \dots + (s_p + t_p) \cdot \mathbf{x}_p$$

Como es posible escribir al vector \mathbf{u} como una combinación lineal de columnas de X (pesadas con factores s), y también es posible escribir a \mathbf{v} de forma análoga (es decir, pesado con factores t), la suma de ellos necesariamente pertenece también a $Col(X)$.

- Para cada \mathbf{u} en $Col(X)$ y cada escalar c , el vector $c\mathbf{u}$ está en $Col(X)$ pues:

$$c\mathbf{u} = c \cdot (s_1 \cdot \mathbf{x}_1 + s_2 \cdot \mathbf{x}_2 + \dots + s_p \cdot \mathbf{x}_p)$$

$$c\mathbf{u} = (c \cdot s_1) \cdot \mathbf{x}_1 + (c \cdot s_2) \cdot \mathbf{x}_2 + \dots + (c \cdot s_p) \cdot \mathbf{x}_p$$

b) Supongamos que cuando hablamos de vectores en \mathbb{R}^n nos referimos a vectores columna de $\mathbb{R}^{n \times 1}$. Mostrar en ese caso que el producto escalar entre dos vectores \mathbf{u}, \mathbf{v} en \mathbb{R}^n puede calcularse como:

$$\mathbf{u} \cdot \mathbf{v} = \mathbf{v}^T \mathbf{u}$$

donde la operación en el lado derecho de la igualdad es el producto de matrices usual.

Aplicando la definición de producto matricial:

$$\begin{aligned}\sum_{i=1}^n \mathbf{u}_{i1} \cdot \mathbf{v}_{i1} &= \sum_{i=1}^n \mathbf{v}_{1i}^T \cdot \mathbf{u}_{i1} \\ \sum_{i=1}^n \mathbf{u}_{i1} \cdot \mathbf{v}_{i1} - \sum_{i=1}^n \mathbf{v}_{1i}^T \cdot \mathbf{u}_{i1} &= 0 \\ \sum_{i=1}^n \mathbf{u}_{i1} \cdot \mathbf{v}_{i1} - \mathbf{v}_{1i}^T \cdot \mathbf{u}_{i1} &= 0 \\ \sum_{i=1}^n \mathbf{u}_{i1} (\mathbf{v}_{i1} - \mathbf{v}_{1i}^T) &= 0\end{aligned}$$

Tal igualdad implica dos casos disjuntos:

- $\sum_{i=1}^n \mathbf{u}_{i1} = 0 \quad \forall 1 \leq i \leq n$ Este caso no va a suceder siempre
- $\sum_{i=1}^n \mathbf{v}_{i1} - \mathbf{v}_{1i}^T = 0 \quad \forall 1 \leq i \leq n$ Este caso sucederá siempre pues:

$$\begin{aligned}\sum_{i=1}^n \mathbf{v}_{i1} - \mathbf{v}_{1i}^T &= 0 \\ \sum_{i=1}^n \mathbf{v}_{i1} &= \mathbf{v}_{1i}^T\end{aligned}$$

Lo cual vale \forall vector \mathbf{v} en \mathbb{R}^n

c) Aplicando el teorema tomando como subespacio S el subespacio del ítem (a), el punto y de \mathbb{R}^n como el vector de la variable dependiente, y el vector b como $b = X\beta^*$, convertir esta ecuación de optimalidad

$$\|y - X\beta^*\| = \min_{\beta \text{ en } \mathbb{R}^p} \|y - X\beta\|$$

en la condición de ortogonalidad que corresponde a la equivalencia 2 del teorema.

Teorema

Sea y un vector cualquiera de \mathbb{R}^n y S un subespacio de \mathbb{R}^n . El vector de S que minimiza la distancia del subespacio S al vector y es aquel b de S tal que $y - b$ es ortogonal a todo vector s de S . Es decir, las siguientes dos condiciones son equivalentes:

1. $\|y - b\| = \min_{s \in S} \|y - s\|$
2. $(y - b) \cdot s = 0$ para todo s en S

Aplicando este teorema con $S = \text{Col}(X)$, el cual demostramos es un subespacio de \mathbb{R}^n , y con $b = X\beta^*$

$$\begin{aligned}\|y - X\beta^*\| &= \min_{s \text{ en } \text{Col}(X)} \|y - s\| \\ \|y - X\beta^*\| &= \min_{s \text{ en } \{b \text{ en } \mathbb{R}^n \text{ tales que } b=X\beta \text{ con } \beta \text{ variando en } \mathbb{R}^p\}} \|y - s\|\end{aligned}$$

Como X es siempre la misma matriz, entonces lo único que va a variar es β , y sabemos que β varía en \mathbb{R}^p . También sabemos que $b = X\beta$, entonces hacemos los reemplazos:

$$\|y - X\beta^*\| = \min_{\beta \text{ en } \mathbb{R}^p} \|y - X\beta\|$$

Luego, por teorema, esta condición es equivalente a la de ortogonalidad, es decir:

$$(y - X\beta^*) \cdot X\beta = 0 \text{ para todo } \beta \text{ en } \mathbb{R}^p$$

d) A la ecuación obtenida en el ítem (c), aplicarle la identidad del producto escalar vista en el ítem (b), para llegar a la ecuación:

$$X^T(y - X\beta^*) \cdot \beta = 0$$

Partiendo de la ecuación obtenida en el ítem (c):

$$(y - X\beta^*) \cdot X\beta = 0 \text{ para todo } \beta \text{ en } \mathbb{R}^p$$

Recordando la propiedad del producto escalar demostrada en (b): $\mathbf{u} \cdot \mathbf{v} = \mathbf{v}^T \mathbf{u}$ donde \mathbf{u}, \mathbf{v} son vectores en \mathbb{R}^n , es posible emplearla tomando los siguientes parámetros:

$$\mathbf{u} = (y - X\beta^*) \text{ pues } \in \mathbb{R}^n \text{ ya que } y \in \mathbb{R}^n \text{ y } X \in \mathbb{R}^{n \times p}, \beta^* \in \mathbb{R}^p \text{ por lo que } X\beta^* \in \mathbb{R}^n$$

$$\mathbf{v} = X\beta \text{ pues } \in \mathbb{R}^n \text{ dado que } X \in \mathbb{R}^{n \times p} \text{ y } \beta \in \mathbb{R}^p$$

Así:

$$(X\beta)^T(y - X\beta^*) = 0$$

Distribución de la transposición

$$\beta^T X^T(y - X\beta^*) = 0$$

Ahora es posible volver a emplear la propiedad de (b) pero en sentido inverso ($\mathbf{v}^T \mathbf{u} = \mathbf{u} \cdot \mathbf{v}$), con estos parámetros y en \mathbb{R}^p en lugar de \mathbb{R}^n :

$$\mathbf{v}^T = \beta^T \text{ pues } \in \mathbb{R}^p \text{ ya que } \beta \in \mathbb{R}^p$$

$$\mathbf{u} = X^T(y - X\beta^*) \text{ pues } \in \mathbb{R}^p \text{ dado que } X^T \in \mathbb{R}^{p \times n} \text{ y } (y - X\beta^*) \in \mathbb{R}^n$$

De esta manera:

$$X^T(y - X\beta^*) \cdot \beta = 0$$

e) Se sabe que el único vector que es ortogonal a todo vector \mathbf{v} de \mathbb{R}^n es el vector nulo. Es decir, si \mathbf{u} es un vector fijo tal que $\mathbf{u} \cdot \mathbf{v} = 0$ para todo \mathbf{v} en \mathbb{R}^n , entonces $\mathbf{u} = \mathbf{0}$. Usando esto y la ecuación obtenida en el ítem (d), llegar a la fórmula:

$$X^T X\beta^* = X^T y$$

Partiendo de la ecuación obtenida en el ítem (d):

$$X^T(y - X\beta^*) \cdot \beta = 0$$

Distribución de X^T

$$(X^T y - X^T X\beta^*) \cdot \beta = 0$$

Esta igualdad se satisface si y solo si se cumple al menos uno de estos casos:

Caso 1: $(X^T y - X^T X\beta^*) = 0$

Caso 2: $\beta = 0$

De la definición de $Col(X)$ provista en el inciso (a) se obtiene que β varía en \mathbb{R}^p , es por esto

que β no puede ser \mathbf{u} en la propiedad del enunciado. Si β no es \mathbf{u} , entonces $\beta \neq \mathbf{0}$, por lo que solo el caso 1 puede ser válido.

Luego, como el caso 1 es el válido:

$$\begin{aligned} X^T y - X^T X \beta^* &= 0 \\ X^T y &= X^T X \beta^* \end{aligned}$$

f) Finalmente, suponiendo que las columnas de X son linealmente independientes, se tiene que la matriz $X^T X$ es invertible. Despejar β^* de la ecuación del ítem (e) para llegar a la fórmula de la solución óptima al problema de regresión.

$$X^T X \beta^* = X^T y$$

Multiplicación a izquierda por $(X^T X)^{-1}$ en ambos lados de la igualdad

$$(X^T X)^{-1} X^T X \beta^* = (X^T X)^{-1} X^T y$$

$$I \beta^* = (X^T X)^{-1} X^T y$$

$$\beta^* = (X^T X)^{-1} X^T y$$